자연어 명령 수행을 위한 관계 인지 기하 그라운딩과 Cost-to-Go MPPI

Taejeong Park[1], Taeyoung Lee[1], Juwon Park[2], Ijun Jo[1], Eunchae Park[1]

[1]*Dept. of Information and Communication Engineering, Dongguk University, Seoul, Republic of Korea*

[2]*Dept. of Mechanical, Robotics and Energy Engineering, Dongguk University, Seoul, Republic of Korea*

ptj1541@gmail.com, xodu00504@dgu.ac.kr, playdoll1235@dgu.ac.kr, jo2june@naver.com, eunchae0923@naver.com

초록—본 논문은 Meta-Sejong AI Robotics Challenge(MARC) 2026 을 위해 언어 기반 CCTV 그라운딩과 모바일 매니퓰레이션을 결합한 모듈형 오프라인 VLA 에이전트를 제시한다. 랜드마크와 구역 단서로 카메라 선택을 제약하고, 관계 인지 순위로 대상–기준물 후보를 결정하며, 발목 보정을 포함한 지지면 투영으로 월드 좌표를 추정한다. 회수 단계에서는 cost-to-go 유도 MPPI(model predictive path integral) 제어가 차체 제약 아래에서 격자 내비게이션 함수를 따라 내려가고, 깊이 우선 점유 격자가 LiDAR 빔 통과 정보와 깊이로 확인된 바닥 셀을 결합하여 반복되는 지면 오분류를 억제한다. 공개 미션 33 개를 7 회 반복한 결과 Stage 1 점수는 75.8/100, 카메라 정확도는 87.9%였다. 공개 회수 미션 5 개에서 최종 구성은 20 회를 모두 완주하였고 깊이 우선 격자는 기록된 밀집 구간 시험에서 경로 소실을 없앴다. 남은 실패는 연석 주변 인식과 관련된다.

키워드—*VLA, 시각 그라운딩, 공간 관계, 기하 기반 위치 추정, MPPI 제어, 점유 격자, 모바일 매니퓰레이션*

I. 서론

MARC 2026 은 Isaac Sim 캠퍼스 디지털 트윈에서 언어 기반 시각 그라운딩과 물체 회수를 함께 다룬다 [1]. Stage 1 은 CCTV 카메라를 선택하고 의미 필드와 월드 좌표를 제출하는 과제이고, Stage 2 는 물체를 회수해 주인에게 전달하는 과제이다. 시야가 거의 겹치지 않는 카메라들에 같은 클래스가 반복되고 검출도 불완전하여 신뢰도만으로는 카메라를 고를 수 없으며, 바운딩 박스는 위치 추정에 필요한 물리적 지점을 직접 알려주지 않는다. 주행에서는 LiDAR 적중만 누적하는 지도가 일시적 반사를 지우지 못하고, 경사에서의 지면 오분류가 같은 바닥 셀을 반복해 장애물로 표시한다. 두 경우 모두 목표로 가는 모든 빈 경로를 막을 수 있다.

본 시스템은 YOLO11 [2], 랜드마크 기반 그라운딩 [3], 광선–평면 기하 [4], MPPI [5]를 바탕으로 한다. 자세는 위험 단서로 단독 사용하지 않고 지지면 문맥과 함께 해석하여, 자세 기반 낙상 검출 [6]을 보완한다. 주요 기여는 다음과 같다.

- **제약 기반 카메라 게이팅과 관계 인지 후보 선택**: 후보 집합을 비우지 않으면서 카메라를 좁힌다
- **자세에 따른 발목 보정을 포함한 지지면 기반 위치 추정**
- **Cost-to-go 유도 MPPI**: Dijkstra cost-to-go 장과 롤아웃 안에서 차체 제약을 지키는 MPPI 제어기의 조합으로, 같은 장애물 지도에서 A* 경로 추종과 비교해 평가한다
- **깊이 우선 점유 격자**: 깊이로 확인된 바닥이 LiDAR log-odds 증거보다 우선한다

II–IV 장은 파이프라인과 두 Stage 를 설명하고, V 장은 공개 미션에서 이를 평가한다. 이 평가는 처음 보는 환경으로의 일반화를 입증하지 않는다.

II. 파이프라인

그림 1 은 전체 시스템을 보인다. 이는 종단 간 정책이 아니라, 언어가 시각을 제약하고 그라운딩 결과가 행동을 이끄는 모듈형 VLA 파이프라인이다. 미션 문자열 m 과 N = 6 대 고정 CCTV 카메라의 프레임은 독립된 두 갈래로 들어간다. 규칙 기반 파서는 공식 에셋 목록의 동의어를 이용해 미션을 대상, 랜드마크, 관계, 자세, 구역 단서로 변환한다. YOLO11 검출기는 34 클래스(대상 10, 랜드마크 15, 자세 9)를 다루며, 보조 타일 검출기가 작은 물체 3 클래스(선크림, 휴지, 일회용 컵)를 처리한다.

Stage 1(III 장)은 두 갈래를 카메라 게이팅과 관계 인지 선택에서 합치고, 사람 미션의 상황을 판단한 뒤 대상과 기준물의 위치를 추정하여 GroundingResult $y = (c^*, o, l, r, s, x_t, x_a)$를 만든다. Stage 2(IV 장)는 y 를 재사용한다. x_t 가 로봇의 LiDAR 와 깊이 카메라로 만든 깊이 우선 점유 격자 위 cost-to-go 장의 목표가 되고, MPPI 가 모바일 매니퓰레이터를 물체까지 주행시키며, 깊이 기반 파지 후 같은 제어기가 물체를 주인 구역까지 전달한다.

III. STAGE 1: 지지면 기반 위치 추정을 포함한 관계 인지 그라운딩

A. 카메라 게이팅과 후보 선택

랜드마크 게이트는 명명된 랜드마크 1 이 검출된 카메라만 남긴다. 구역 게이트는 주차장의 차량, 공원의 벤치나 피크닉 테이블처럼 구역을 나타내는 물체를 이용해 우세한 카메라를 남긴다.

$$G_L = \{\, c : \exists\, d \in D_c,\ \mathrm{class}(d) \approx l \,\} \tag{1}$$

$$G_A = \{\, \mathrm{argmax}_c\, n_c \,\} \quad \text{if } n^{(1)} \geq \gamma\, n^{(2)} \tag{2}$$

여기서 D_c는 카메라 c 의 검출 집합, n_c는 지시 물체 수, $n^{(1)}$, $n^{(2)}$는 가장 큰 두 개수이다. 해당하는 게이트는 교집합으로 결합하고, 후보 집합이 비지 않도록 랜드마크 게이트 또는 전체 카메라로 되돌린다. 이 폴백은 랜드마크가 검출되지 않았을 때 정답 카메라가 남는 것을 보장하지 않는다.

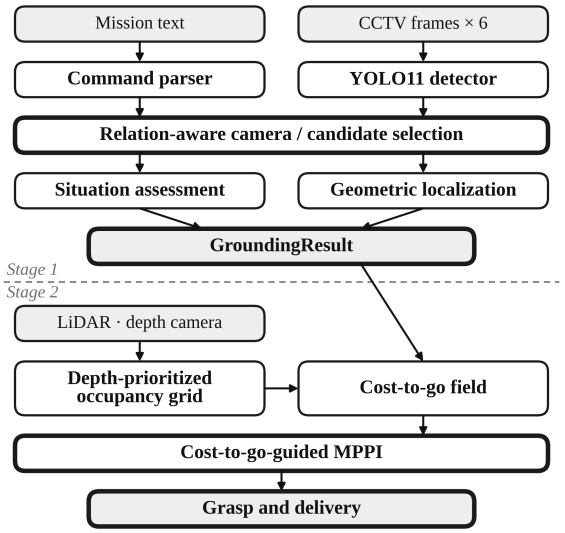


그림 1. 시스템 파이프라인. Stage 1 은 CCTV 화면에서 미션을 그라운딩하고, Stage 2 는 x_t로 주행해 물체를 파지한 뒤 전달한다.

각 카메라 안에서는 footprint 간격을 이용해 대상을 가장 가까운 기준물과 짝짓는다. g 를 방향 박스(OBB) 표면 간격, δ_{near}를 근접 척도라 하면 근접도와 카메라 간 순위는 다음과 같다.

$$\pi = \max(\,0,\, 1 - \max(0, g) \,/\, \delta_{near}\,) \tag{3}$$

$$c^{*} = \operatorname{argmax}_{c \in G}\, \kappa_c, \quad \kappa_c = (\,b_c, \pi_c, s_c\,) \tag{4}$$

여기서 b_c 는 관계 일치, s_c 는 검출 신뢰도이며 κ 는 사전식으로 비교한다. 사람 미션은 관계가 채점되지 않고 누운 사람의 박스가 footprint 를 왜곡할 수 있어 $\kappa_c = (\pi_c, b_c, s_c)$를 쓴다. 랜드마크가 없는 열린 공간 명령에서는 최선 후보들이 모호하지 않는 한 랜드마크와의 거리가 가장 먼 대상을 고른다. 기준물 위에서 대상이 검출되지 않은 on 명령에는 국소 저임계 재검출을 수행한다.

B. 상황 판단과 기하 기반 위치 추정

상황 판단은 무력화 우선 규칙을 적용한 뒤, 주최 측의 자세–지지면 규칙 [1]을 네 자세 그룹(검출기 라벨에서 도출)과 다섯 지지면 그룹에 적용한다. 지지면은 on/above 관계에서는 랜드마크로, 그 밖에는 구역 단서로 추론하므로, 같은 누운 자세라도 잔디와 통행 구역에서는 다른 상황이 될 수 있다.

영상 점 (u, v), 내부 행렬 K, 카메라–월드 회전 R_{wc}, 카메라 중심 C 에 대해 시선 광선은 지지 평면 $z = h$ 와 다음에서 만난다 [4].

$$d_w = R_{wc}\, K^{-1}\, [u, v, 1]^{\top}, \quad X_w = C + (h - C_z) \,/\, (d_w)_z \cdot d_w \tag{5}$$

기본 점은 박스 아랫변 중앙 $(u, v) = ((x_{min} + x_{max})/2, y_{max})$이며, 이는 물체의 카메라 쪽 가장자리에 놓인다고 근사한다. 이 점을 박스 아랫변의 투영 폭의 절반인 footprint 반경 ρ 만큼 카메라 반대 방향으로 민다.

$$\hat{X} = X_w + \rho\, e, \quad e = [(X_w - C)_x, (X_w - C)_y, 0]^{\top} \,/\, \|\cdot\| \tag{6}$$

모든 기하는 영상과 플랫폼이 카메라마다 제공하는 지면 높이 h 에서만 얻으며, 에셋 치수나 지도 기하는 쓰지 않는다. footprint 는 시선 방향에 정렬된 OBB 로, 가로 반길이가 ρ 이다. 단일 시점에서는 깊이를 관측할 수 없으므로 깊이 반길이도 ρ 로 둔다(정사각형 footprint). 기준물에 놓인 대상은 기준물 윗면으로 투영하며, 윗면 높이는 클래스 상수 없이 박스 상단 중앙을 지나는 광선이 footprint 먼 쪽 가장자리의 수직선과 만나는 높이로 객체마다 추정한다. 관계는 XY footprint 기하로 판정한다. beside/near 는 OBB 표면 간격으로, on/above 는 수직 배치까지 함께 본다. 사람 대상은 발목 keypoint (u_a, v_a)로 박스 점을 대체한다.

$$\begin{cases} (u, v, \rho) = (u_a, v_a, 0) & \text{엎드리거나 누운 자세} \\ (u, v, \rho) = (u_a, y_{max}, \rho) & \text{그 밖의 자세} \end{cases} \tag{7}$$

keypoint 는 COCO 사전학습 모델에서 얻는다. 엎드리거나 누운 자세에서는 박스 아랫변이 발보다 가까운 신체 부위일 수 있다. 서 있는 사람은 얕은 시야각에서 세로 오차가 커지므로 박스 아랫변의 행을 유지한다.

IV. STAGE 2: 깊이 우선 점유 격자를 이용한 COST-TO-GO 유도 MPPI

A. Cost-to-Go 유도 MPPI

매 갱신마다 0.2 m 격자에 정적 지도와 감지된 장애물을 합친다. 각 셀의 단위 길이당 비용 q(x)는 다음과 같다.

$$q(x) = 1 + w_i\, e^{-\alpha(d(x) - r_{in})} + w_u\, u(x) + w_s\, s(x) \tag{8}$$

여기서 d(x)는 가장 가까운 통행 불가 셀까지의 거리, r_{in} = 0.3 m 는 로봇 내접 반경, u(x)는 도로 밖 지시자, s(x)는 식 (16)의 점유 소프트 비용이며, $d(x) < r_{in}$ 인 셀은 통행 불가이다. 목표 x_g 에서 8-이웃 $\mathcal{N}$ 으로 Dijkstra 탐색을 하면 cost-to-go 장을 얻는다 [7].

$$V(x) = \min_{x' \in \mathcal{N}(x)} [\, V(x') + \bar{q}(x, x')\, \|x - x'\| \,] \tag{9}$$

$\bar{q}$ 는 두 셀 비용의 평균이고 $V(x_g) = 0$ 이다. 격자 위의 V 에는 목표 외의 가짜 극소가 없어 MPPI 에 일관된 하강 방향을

주지만, 이것만으로 운동 제약 아래의 도달이 보장되지는 않는다. MPPI [5], [8]는 $T = 25$ 스텝($\Delta t = 0.1$ s)에 걸친 제어열 $u_t = (v_t, \omega_t)$를 $M = 1{,}024$ 개 샘플링하고 각 롤아웃을 다음으로 평가한다.

$$J = \Sigma_t[w_p V_t + w_\varphi \varphi_t + w_h(1 - \cos \Delta\theta_t)]\Delta t + w_g V_T + w_c N_{col} \quad (10)$$

여기서 $V_t = V(x_t)$, φ_t는 장애물 근접 비용, $\Delta\theta_t = \theta_t - \theta_{\nabla V}$는 V의 하강 방향에 대한 헤딩 오차, N_{col}은 충돌 스텝 수이다. 평활화 항과 후진 항은 생략하였다. 공칭 제어열은 지수 가중한 섭동 ε_m으로 갱신한다.

$$w_m \propto \exp(-(J_m - J_{min})/\lambda), \quad u_t \leftarrow u_t + \Sigma_m w_m \varepsilon_{m,t} \quad (11)$$

각 롤아웃 안에서 명령은 차체 제약으로 사영된다.

$$|v| \le 1.1 \text{ m/s}, \quad |v\,\omega| \le a_{lat}, \quad |\omega| \le \min(1.2,\ 1.8\,|v|/b) \quad (12)$$

횡가속도 $a_{lat} = 1.0$ m/s², b는 윤거이며, 제자리 회전에서는 조향 한계를 풀어준다. 큰 헤딩 변화를 위해 시간 상관 무작위 샘플에 정형화된 선회 및 회전 후 주행 후보를 더한다. 지면 높이 불연속에서 추출한 연석·턱 선은 롤아웃 충돌 검사에 포함되고, 그 근처에서는 속도를 낮춘다.

B. 깊이 우선 점유 격자와 파지

LiDAR 가 맞은 셀을 모두 막으면 일시적 반사가 쌓여 목표가 둘러싸이므로, 각 0.1 m 셀은 log-odds 값 L을 유지한다 [9], [10].

$$L(x) \leftarrow \text{clip}(L(x) + \ell, L_{min}, L_{max}), \quad \ell \in \{\ell_{occ}, \ell_{free}\} \quad (13)$$

LiDAR 적중은 $\ell_{occ} = 0.85$, 빔이 통과한 셀은 $\ell_{free} = -0.4$를 더하며, OctoMap 설정 [11]에 따라 $[L_{min}, L_{max}] = [-2, 3.5]$로 제한한다. 센서 높이 h_s에서 지면에 닿는 거리 R_b의 빔은 장애물 대역 $z_0 = 0.15$ m 위에 있는 구간에서만 빈 공간 증거를 준다.

$$R_{free} = R_b\,(1 - z_0 / h_s) \quad (14)$$

경사로 인한 지면 오차는 같은 셀에서 반복되므로, 관측을 반복할수록 평균되지 않고 오히려 굳어진다. 따라서 깊이 카메라가 바닥으로 확인한 셀 집합 F_d를 우선한다.

$$L(x) \leftarrow L_{min} \quad \text{for } x \in F_d \quad (15)$$

F_d는 깊이 프레임마다 새로 만든다. 4 m 이내의 낮은 점들에 평면 $z = p_x x + p_y y + p_0$를 최소제곱으로 적합하고, 경사를 따라가도록 $|p_x|, |p_y| \le 0.27$(각 축 방향으로 약 15°)이면 채택하며, 그렇지 않으면 높이 하위 5%를 평평한 기준으로 쓴다. 평면에서 0.05 m 이내의 픽셀은 바닥, 0.15–1.8 m 위는 장애물이다. 실제 장애물이 지워지지 않도록, 바닥이 유효 픽셀의 30% 미만이거나 아래 시야가 대부분 가려진 프레임은 건너뛰고, 같은 2° 방위에서 더 가까운 장애물 너머의 바닥은 가림 그림자로 버리며, 같은 프레임에서 장애물 점이 들어온 셀은 초기화하지 않는다.

0.2 m 계획 격자는 셀 안의 최댓값 대신 각 셀 중심의 L을 샘플링하여, 작은 장애물이 부풀지 않고 좁은 틈이 유지되게 한다. $L \ge L_h = 2.5$인 셀은 통행 불가이고, 더 약한 증거는 내접 반경만큼 팽창된 소프트 비용으로 식 (8)의 $q(x)$에 들어가므로($L_s = 0.4$) 불확실한 셀이 목표를 막지 않는다.

$$s(x) = \max_{\|x' - x\| \le r_{in}} \text{clip}(\,(L(x') - L_s)\,/\,(L_h - L_s),\ 0,\ 1\,) \quad (16)$$

파지를 위해 깊이 점을 팔 좌표계로 변환하고 바닥 위 점들을 군집화한 뒤, 주행 추정 위치에 가장 가까운 군집을 고른다. 서 있는 물체는 윗면 중앙을 파지하고, 누운 물체는 주축 기하로 그리퍼 방향을 정한다. 검출된 연석은 파지 후보에서 제외한다. 로봇은 팔을 접은 채 접근해 정렬한 뒤 파지하며, 피드백에 따라 최대 세 번 재시도한다.

V. 실험 결과 및 논의

A. Stage 1 평가와 누적 비교

Stage 1 은 공개 충무 미션 33 개 전체(사람 14, 분실물 19)를 사용하며, 구성마다 네트워크를 끊은 라이브 실행을 7 회 반복하였다. 의미 필드는 완전 일치로, 좌표는 XY 오차로 채점한다. 표 I–II 는 평균 ± 표준편차이다. 검출기는 플랫폼이 생성한 검증 장면 500 개에서 mAP50 = 0.841 을 얻었고, 타일 검출은 작은 물체 재현율을 0.42–0.50 에서 0.58–0.71 로 높였다.

최종 구성은 모든 실행에서 33 라운드 중 29 라운드의 카메라를 맞혔고, 대상 유형과 상황 범주는 모두 정답이었다. 평균 총점은 75.8/100 이며, 카메라 오류 4 건은 정답 카메라에서 대상이 검출되지 않은 경우였다. 표 I 에서 카메라 정확도의 가장 큰 증가는 구역 게이트에서 나타났고, 최종 구성은 사람 미션의 카메라를 모두 맞혔다. 이 누적 비교는 독립된 효과가 아니라 앞선 구성 요소를 전제로 한 개선을 측정한다.

표 I. 카메라 선택 누적 결과 (7 회, 평균 ± 표준편차)

구성	카메라 (%)	점수 /100
G0 신뢰도만	33.8 ± 1.1	44.8 ± 0.5
G1 + 랜드마크 게이트 (1)	40.7 ± 1.6	49.1 ± 1.0
G2 + 구역 게이트 (2)	75.8 ± 0.0	70.1 ± 1.8
G3 + 관계 순위 (3)–(4)	84.8 ± 0.0	75.5 ± 1.7
G4 + 사람 근접 우선 (최종)	87.9 ± 0.0	75.8 ± 0.6

표 II 는 위치 추정 단계를 비교한다. footprint 보정은 카메라를 맞힌 물체 라운드에서 기준물 오차를 1.74 m 에서 0.64 m 로 줄였다. 이어지는 지지면 높이 보정이 이

순서에서 가장 큰 총점 증가를 가져왔다. 국소 재검출은 on 명령 점수를 높였고, 발목 보정은 사람 오차를 0.93 m 에서 0.75 m 로 줄였다. 작은 점수 차이는 통계적으로 유의한 근거로 보지 않는다. 대상 점수가 0 인 라운드의 약 절반은 정답 카메라에서 대상을 놓친 경우로, 기하 보정만으로는 해결되지 않는 한계이다.

표 II. 위치 추정 누적 결과 (7 회, 평균 ± 표준편차)

구성	점수	On 점수	사람 (m)
C0 박스 중앙	59.9 ± 1.7	37.5 ± 0.0	2.00 ± 0.01
C1 박스 아랫변 (5)	64.7 ± 0.8	47.3 ± 0.0	1.49 ± 0.00
C2 + Footprint (6)	63.2 ± 1.0	43.7 ± 0.0	1.46 ± 0.00
C3 + 지지면 높이	72.3 ± 1.4	68.1 ± 0.0	0.93 ± 0.00
C4 + 재검출	73.8 ± 1.4	75.5 ± 1.9	0.93 ± 0.00
C5 + 발목 (7) (최종)	75.8 ± 0.6	76.0 ± 3.4	0.75 ± 0.00

On 점수는 on 명령 11 개의 평균이다. 사람 오차는 사람 미션 14 개의 실행별 중앙값을 실행에 걸쳐 평균한 값이다. C4 는 기하만이 아니라 검출을 바꾼다.

B. Stage 2 회수와 장애물 표현

공개 미션 5 개는 텀블러와 우산에 대한 자연어 회수 명령을 다루며, 그중 두 개는 택시 주변 밀집 장애물 구간이다. 파지(50)와 전달(30) 점수가 회수 소계를 이룬다. 완주는 로봇이 주인 구역에 도달해 전달 점수를 받은 경우로, 올바른 물체를 잡았는지와 무관하며 파지 정확도는 따로 보고한다. 감시 구간 동안 작업 단계 진행도, 목표까지 직선거리 0.3 m 이상 감소도 없으면 0 점으로 중단하며, 복구 동작 중에는 구간을 연장한다. 표 III 은 초기 구현(A* + 비례 제어 + 원호 우회)과 최종 시스템을 각 문제 당 4 라운드에 걸쳐 비교한다. 가운데 열(초기 원판 장애물 위의 MPPI)은 최종 시스템으로 가는 중간 단계로, cost-to-go 유도 MPPI 와 깊이 우선 격자의 기여를 나누어 보여준다. 표 IV 는 MPPI 를 고정한 채 밀집 구간을 비교한다.

표 III. 회수 미션 5 개 결과 (4 라운드, 구성별 20 회)

지표	A* + P 제어 (원판)	MPPI (원판)	MPPI (깊이 격자)
완주 / 실행	9/20	18/20	20/20
회수 점수 /80	36.0 ± 40.8	69.5 ± 26.3	75.0 ± 15.4
Stage 2 점수 /100	42.8 ± 48.7	82.5 ± 30.2	90.1 ± 14.5
올바른 파지[1]	9/20	17/20	18/20
주행 시간 (s)[2]	107.1	117.9	85.0
실행당 제동	15.0	4.6	1.0
경로 소실 실행	–	7	0

[1] 완주한 실행만 채점하는 플랫폼이 확인한 올바른 파지. [2] 세 구성이 모두 완주한 미션별 평균의 평균. 제동: LiDAR 근접 정지. 경로 소실: 장 빌드 중 로봇 위치에서 V = ∞가 된 실행.

같은 원판 장애물에서 cost-to-go 유도 MPPI 는 완주를 9/20 에서 18/20 으로 높이고 실행당 제동을 15.0 에서 4.6 으로 줄였다. 초기 구현은 주로 전달 구간에서 A* 경로를 잃고 멈췄지만, cost-to-go 장은 하강 방향을 유지했다. 남은 실패와 느린 주행은 택시 주변 밀집 구간의 경로 소실(7 회)에서 나왔다. 깊이 우선 격자는 경로 소실을 없애 20 회를 모두 완주했고, 공통 미션 주행 시간을 85.0 s 로, 실행당 제동을 1.0 으로 낮췄다.

밀집 구간 시험은 MPPI 를 유지한 채 장애물 표현만 바꾸었다(표 IV). 빔 통과 정보로 지우지 않는 원판 방식은 8 회 중 5 회에서 경로 소실(로봇 위치에서 V = ∞)을 일으켰다. 일반 점유 격자는 경사로 인한 오차가 반복해 쌓여 깊이 카메라가 바닥으로 본 셀까지 통행 불가가 되면서 시험한 두 실행 모두 실패했다. 점유격자와 깊이 우선을 결합한 방식은 텀블러와 우산 시험을 각각 4 회 모두 평균 107.2 s 와 110.8 s 에 완주했으며 경로 소실과 완화된 장 빌드는 없었다. 시험 횟수가 적고 고르지 않아 비교에는 한계가 있다.

표 IV. 밀집 구간 장애물 표현별 결과 (MPPI)

장애물 표현	완주[1]	경로 소실	완화 빌드[2]	시간 (s)[3]
원판	3/4; 3/4	5/8	114.4	145.4; 172.8
점유 격자 (13)–(14)	0/1; 0/1	2/2	70.0	—
+ 깊이 우선 (15)	4/4; 4/4	0/8	0	107.2; 110.8

[1] 텀블러; 우산. [2] 실행당 장애물 제약을 완화한 장 빌드 수. [3] 완주한 텀블러; 우산 시험의 평균.

자판기 옆 우산에서 남은 파지 실패(최종 4 회 중 2 회)가 나타난다. 연석 선 제외가 불완전하면 근처 연석이 깊이 탐색 창에서 길쭉한 물체로 보인다. 대상 크기 제약이나 로봇 카메라 검증이 대안이 될 수 있으나 평가하지는 않았다.

VI. 향후 연구

파서와 검출기는 고정 어휘를 쓴다. 등록되지 않은 표현을 위한 로컬 언어 모델 확장과 개방 어휘 재검출을 위한 Grounding DINO [12]는 시험 환경의 VRAM 제한으로 신뢰성 있게 평가할 수 없어 사용하지 않았으며, 예비 시험에서는 관계를 잘못 지정하는 경우가 있었다. 충분한 메모리에서 이를 평가하고 검출 재현율을 높일 계획이다.

VII. 결론

본 논문은 제약 기반 카메라 게이팅, 관계 인지 선택, 지지면 기반 위치 추정, 깊이 우선 점유 격자를 이용한 cost-to-go 유도 MPPI 를 결합한 MARC 2026 용 오프라인 VLA 에이전트를 제시했다. Stage 1 에서는 구역 게이트와 지지면 높이 보정의 효과가 가장 컸다. Stage 2 에서 최종 구성은 완주를 9/20 회에서 20/20 회로 높였다. 같은 장애물 지도에서 cost-to-go 유도 MPPI 가 대부분의 향상(18/20)을 만들었고, 깊이 우선 방식이 남은 경로 소실을 없앴다. 연석과 관련된 파지 모호성이 주된 실패 원인으로 남아 있다.

참고문헌

[1] MARC 2026 Organizing Committee, "MARC 2026 Developer Guide," ver. 2026.1.0, 2026. [Online]. Available: https://marc-challenge.github.io/marc-dev-guide/en/

[2] G. Jocher and J. Qiu, "Ultralytics YOLO11," software, ver. 11.0.0, 2024. [Online]. Available: https://github.com/ultralytics/ultralytics

[3] M. Berg, D. Bayazit, R. Mathew, A. Rotter-Aboyoun, E. Pavlick, and S. Tellex, "Grounding language to landmarks in arbitrary outdoor environments," in Proc. IEEE Int. Conf. Robot. Autom. (ICRA), 2020, pp. 208-215.

[4] R. Hartley and A. Zisserman, Multiple View Geometry in Computer Vision, 2nd ed. Cambridge, U.K.: Cambridge Univ. Press, 2004.

[5] G. Williams, P. Drews, B. Goldfain, J. M. Rehg, and E. A. Theodorou, "Aggressive driving with model predictive path integral control," in Proc. IEEE Int. Conf. Robot. Autom. (ICRA), 2016, pp. 1433-1440.

[6] D. R. Beddiar, M. Oussalah, and B. Nini, "Fall detection using body geometry and human pose estimation in video sequences," J. Vis. Commun. Image Represent., vol. 82, Art. no. 103407, 2022.

[7] J.-C. Latombe, Robot Motion Planning. Boston, MA, USA: Kluwer Academic, 1991.

[8] G. Williams, P. Drews, B. Goldfain, J. M. Rehg, and E. A. Theodorou, "Information-theoretic model predictive control: Theory and applications to autonomous driving," IEEE Trans. Robot., vol. 34, no. 6, pp. 1603-1622, 2018.

[9] A. Elfes, "Using occupancy grids for mobile robot perception and navigation," Computer, vol. 22, no. 6, pp. 46-57, 1989.

[10] S. Thrun, W. Burgard, and D. Fox, Probabilistic Robotics. Cambridge, MA, USA: MIT Press, 2005.

[11] A. Hornung, K. M. Wurm, M. Bennewitz, C. Stachniss, and W. Burgard, "OctoMap: An efficient probabilistic 3D mapping framework based on octrees," Auton. Robots, vol. 34, no. 3, pp. 189-206, 2013.

[12] S. Liu et al., "Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection," in Proc. Eur. Conf. Comput. Vis. (ECCV), 2024, pp. 38-55.